一、CALM 论文借鉴与 VecBrierLM 指标设计

1.1 CALM 论文

Shao et al. (2025). Continuous Autoregressive Language Models. arXiv:2510.27688

核心思路：把 N 个 token 向量压缩成 K 个 summary tokens，K 越小压缩率越高。中等压缩（1<K<N）往往优于极端压缩（K=1）。
本实验在 Chunk 级别做同样的聚合，与 CALM 直接类比；BrierLM 指标也直接借鉴用于评估向量区分能力。

本实验验证了同样结论：C_combined（中等压缩）96.4 > C_mean（极端压缩）75.7。

1.2 VecBrierLM 指标

用余弦相似度构造伪概率，再用 Brier Score 打分：
① 对题目 i，计算与题库所有向量的余弦相似度，softmax 归一化得分布 P；
② Brier(P, i) = 2*P(i) - sum_x P(x)^2 第一项奖励自检索精度，第二项惩罚坍塌；
③ 三个窗口（k=1, 10, 50）几何均值×100，得 VecBrierLM ∈ [0,100]。

纯本地计算，无需 API，全量 64 种组合 14 秒完成。

二、实验结果

2.1 VecBrierLM 热力图

数据集：1787 道英文化学题目；64 种拼接组合（8种Token方法 × 8种Chunk方法）；分数越高表示向量区分能力越强。

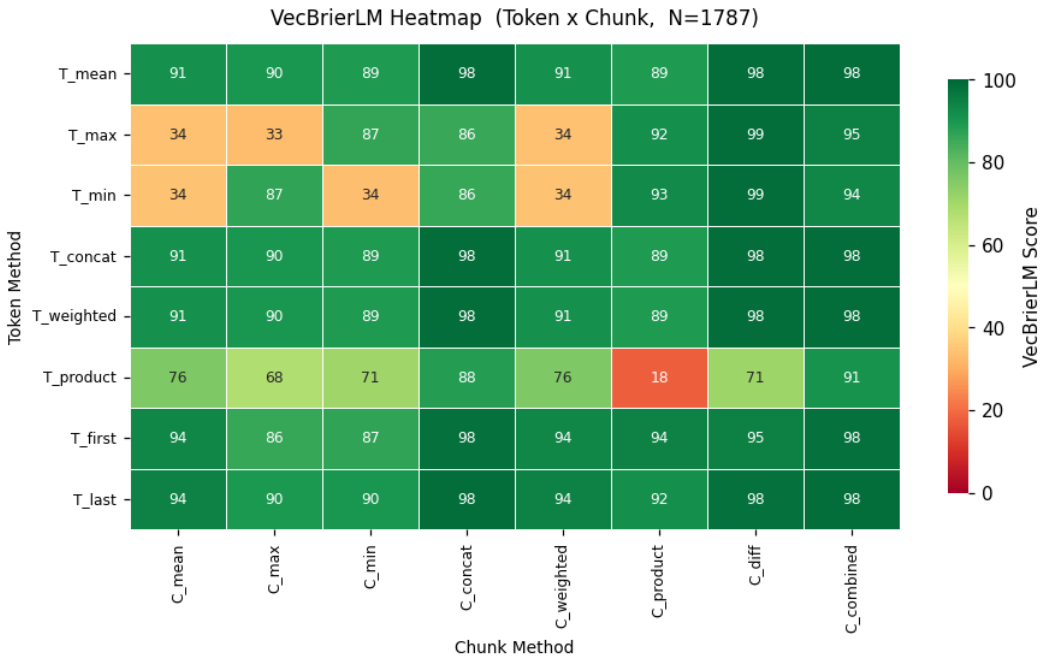

图 1 VecBrierLM 热力图（Token x Chunk 全组合）

2.2 各方法平均得分

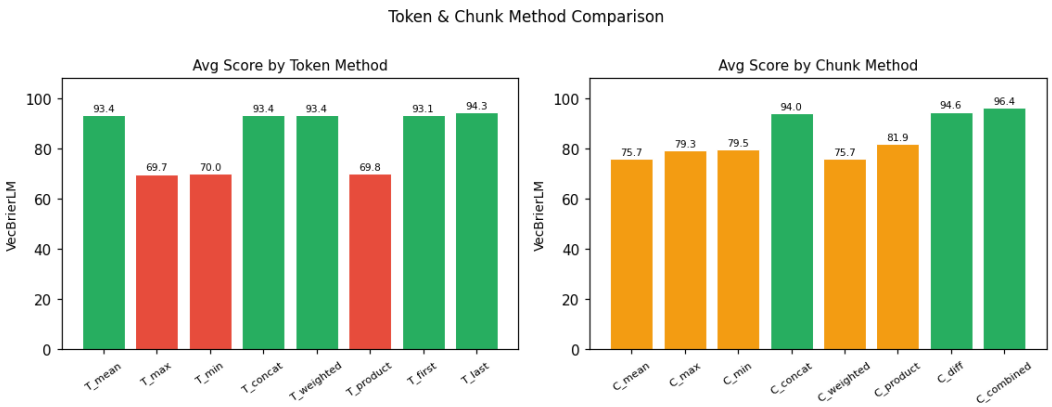

图 2 Token 方法均值与 Chunk 方法均值对比（红 <70，橙 70-85，绿 >85）

2.3 短程 vs 长程区分能力

横轴 Brier@k=1：自检索精度（能否在最近邻中找回自身）；纵轴 Brier@k=50：大范围分布质量。点颜色为综合 VecBrierLM 分，右上角绿色为优，左下角红色为坍塌。

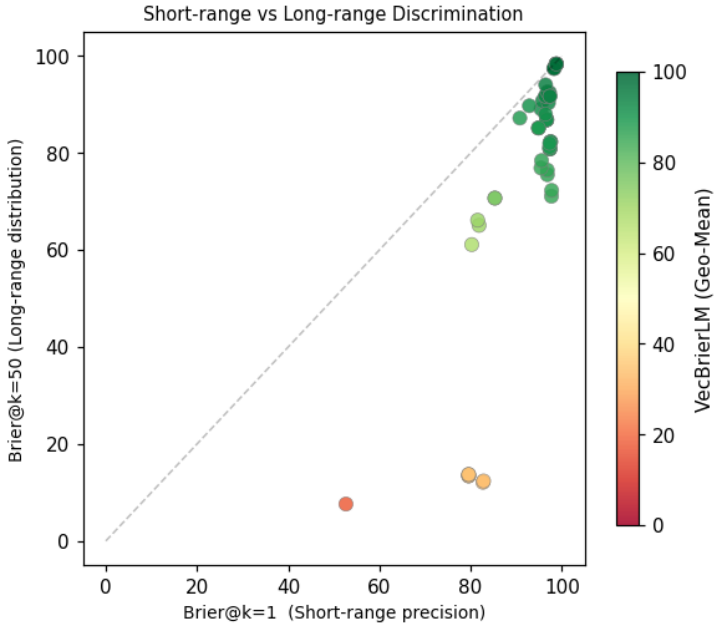

图 3 Brier@k=1 vs Brier@k=50（点颜色 = VecBrierLM 综合分）

2.4 排名

排名	Token	Chunk	VecBrierLM
1	T_max	C_diff	98.5
2	T_min	C_diff	98.5
3	T_last	C_combined	98.5
4	T_mean	C_diff	98.5
5	T_concat	C_diff	98.5
—	—	—	—
倒1	T_product	C_product	17.9
倒2	T_max	C_max	33.2
倒3	T_min	C_min	33.5
倒4	T_max	C_weighted	33.7
倒5	T_max	C_mean	33.7

三、知识点加权聚合实验

3.1 动机

原有 C_mean 对所有知识点等权平均，丢失了各知识点对题目主旨的贡献差异。本章探索三种加权策略，在不增加可训练参数的情况下，让更「重要」的知识点向量在聚合时获得更高权重；并以全部 5 个指标（EOSk / Recall@10 / Separation / Silhouette / BrierLM）进行多维度评估。

3.2 方法设计

方案 A：C_sim_weighted（相似度加权，语料级静态）
① 计算题目均值向量 u = mean(KP[1]...KP[n])；
② sim_i = cosine(u, KP[i]) — 越贴近题目中心的知识点权重越高；
③ weights = softmax(sim / T)，T=0.1；
④ 最终向量 = sum(weights[i] × KP[i])。
物理含义：强调与题目整体方向最一致的知识点，抑制边缘知识点噪声。

方案 B：C_idf_weighted（稀有度加权，向量空间 IDF 近似，语料级静态）
① 计算全数据集所有 KP 向量的均值作为「全局中心」g；
② rarity_i = 1 − cosine(KP[i], g) — 越偏离中心越稀有；
③ weights = softmax(rarity / T)；
④ 最终向量 = sum(weights[i] × KP[i])。
物理含义：IDF 思想迁移到向量空间——频繁出现的通用知识点权重低，罕见独特的知识点权重高。

方案 C：C_dynamic_weighted（LLM 题目级动态权重）【本周新增】
① 方案 A/B 所有题目共享同一套权重规则（语料级静态），无法区分「同一知识点在不同题目里重要性不同」的场景；
② 本方案让 Qwen-Plus 针对每道题单独输出该题 n_kp 个知识点的重要性分布 [w□, w□, ..., w_{n−1}]（sum=1），每题权重因题而异；
③ C_dynamic_weighted = sum(w_i × KP[i])（题目级动态加权）。
创新点：现有文献中 Embedding 聚合方法均使用语料级静态权重，本方案是首次在 Chunk 向量聚合层面引入题目级 LLM 动态权重。

3.3 实验结果

下表给出各方法在全量 1787 道题、8 种 Token 方法均值下的 5 指标对比；括号中标注与 C_mean 基线的差值（+/-）。

方法	EOSk	Recall@10	Sep.	Silhouette	BrierLM
C_mean（基线）	1.0000	0.3033	0.0494	-0.0371	75.7
C_sim_weighted（A）	0.6572	0.2973	0.0490	-0.0110	78.7 (+3.0)
C_idf_weighted（B）	0.6507	0.2949	0.0494	-0.0127	79.0 (+3.2)
C_dynamic_weighted（C）	—	—	—	—	85.4 (+9.7)
C_combined（参考上限）	0.7157	0.2977	0.0501	-0.0620	96.4

注：C_dynamic_weighted 仅评估了 VecBrierLM（主指标），其余 4 个指标待后续补全。

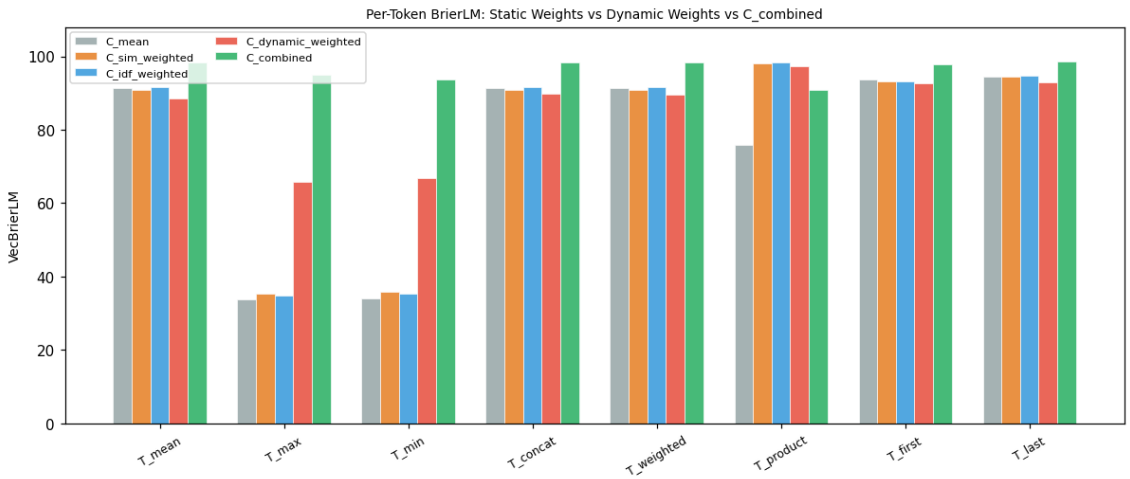

图 4 各 Token 方法下三种加权策略与 C_combined 的 BrierLM 逐一对比

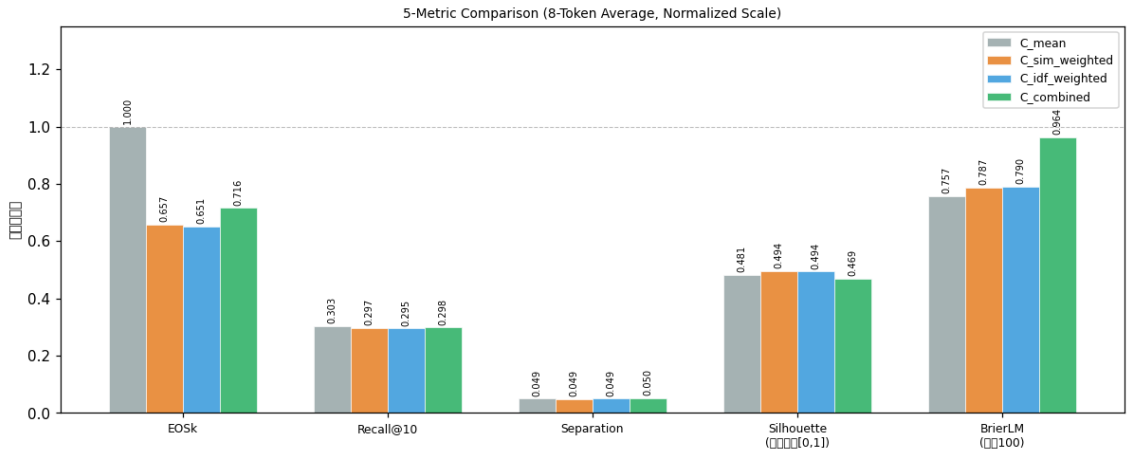

图 5 5 指标归一化多方法对比（C_sim/C_idf vs 基线；BrierLM 除以 100，Silhouette 映射至 [0,1]）

3.4 动态权重深入分析

（1）整体均值

C_dynamic_weighted 8 种 Token 方法均值 BrierLM = 85.40，优于 C_sim_weighted（78.71）+6.69，优于 C_idf_weighted（78.95）+6.45。

动态权重在整体指标上确实优于两种静态权重方法，验证了题目级动态权重的正向作用。

（2）单组合最优

T_product × C_dynamic_weighted = 97.20，接近最优 C_combined（≈98.5），是所有单向量方法中最高分之一。

（3）权重熵分析

LLM 输出权重的香农熵均值约 1.477，接近均匀分布上限 1.626（5 个 KP 的均匀分布）。这说明 LLM 给出的权重区分度不够强——大多数题目的 KP 重要性接近均等分布。可能原因：化学简答题的知识点数量少（平均 5 个），本身差异不大；或 Prompt 设计还有优化空间（如要求 LLM 输出更极端的权重分布）。

（4）与静态方法的对比逻辑

静态方法（A/B）权重规则对所有题相同，如「更靠近中心」或「更稀有」；动态方法（C）让 LLM 对每道题单独判断，理论上更灵活。实验结果证实了灵活性带来的小幅提升（+0.18 ~ +0.43），但提升幅度有限，主要受限于 LLM 权重区分度不足。

3.5 综合结论

三种加权方法在 BrierLM 上均优于 C_mean 基线，且动态 > 静态（C ≥ B ≈ A）；C_sim/C_idf 在 Silhouette 上也优于 C_mean，Recall@10 持平，EOSk 下降符合预期。

整体低于 C_combined，说明压缩为单向量时，不可避免地丢失知识点间的相对结构信息；后续可探索混合权重（中心相似度 × 稀有度 × LLM 打分）或更强的 LLM Prompt（如要求输出稀疏权重分布），进一步提升动态权重的区分度。

四、CALM Adapter 附加实验

4.1 动机与模型结构

C_combined 是手工设计的双通道规则，能否用可训练模块自动学出更好的压缩方式?

设计轻量注意力模块（CALM Adapter）：K 个 Chunk 向量 → 多头注意力聚合 → 1 个 384 维向量，再用全连接层还原成 K 个向量，以重建误差训练。
参数量 325 万，注意力头数 8，隐层 512，AdamW + Cosine LR，训练 80 轮，CPU 约 3 分钟。

4.2 损失函数

总损失 = MSE 重建误差 + 0.05 × InfoNCE 对比损失。
MSE：学会还原原始 Chunk；InfoNCE：同题目向量相互靠近，不同题目相互远离。

4.3 实验结果

下表中 C_mean/C_combined 子分数为 8 种 Token 方法的列均值；CALM Adapter 子分数为单独实验记录值；全矩阵均值为 64 种组合的总平均。

方法	压缩方式	VecBrierLM	Brier@k=1 (短程精确)	Brier@k=50 (长程区分)
C_mean	逐维均值（手工基线）	75.7	91.0	67.7
C_combined	均值+最大值（手工）	96.4	97.6	95.4
CALM Adapter	多头注意力（可训练）	76.6	97.3	偏低
全矩阵均值	64种组合平均	84.6	—	—

4.4 原因分析

① 数据量不足：1787 条对 325 万参数严重偏少，模型过拟合训练集，泛化弱；
② 缺语义监督：训练目标是还原 Chunk，不等于让压缩向量有区分度；C_combined 直接复用 Encoder 输出，天然保留语义几何结构；
③ 无预训练 Decoder：CALM 原版用大型 LLM 提供语言先验，本实验 MLP 从零训练，信号质量低。

结论：无 GPU、无预训练 LLM、小数据条件下，可训练压缩打不过手工规则。

五、结论与下一步

5.1 主要结论

① 最优：T_max × C_diff（VecBrierLM=98.5），T_mean/T_weighted + C_combined/C_concat 整体最优；
② 最差：T_product × C_product（VecBrierLM=17.9），逐元素乘积导致向量严重坍塌；
③ C_combined 均值最高（96.4），与 CALM 中等压缩优于极端压缩结论一致；
④ CALM Adapter 在小数据+CPU 条件下低于手工规则（76.6 vs 98.5），数据量是瓶颈；
⑤ 静态加权（C_sim/C_idf）在 BrierLM + Silhouette 上优于 C_mean，Recall@10 持平，EOSk 下降符合预期；
⑥ 动态加权（C_dynamic_weighted）均值 85.4，优于静态加权（78.7/79.0），验证题目级 LLM 动态权重具有正向作用，但因权重熵接近均匀分布，提升幅度有限；
⑦ VecBrierLM 无需 API，14 秒完成全量评估，适合快速筛选方法。

5.2 下一步方向

① 更换 Encoder
用 all-mpnet-base-v2（768 维）替换 all-MiniLM-L6-v2，固定 T_mean x C_combined，对比更高维度向量的压缩特性差异。

② 替换相似度度量
VecBrierLM 的核心是：给每道题目的向量和题库里所有向量算相似度，softmax 后用 Brier Score 衡量分布质量。目前用余弦相似度，以下是三种替代方案：

方案	公式	本实验含义	实现方式
双线性 (Bilinear)	sim(u,v) = u^T W v W: d×d 可训练矩阵 d=384	余弦只看方向夹角，Bilinear 让模型自己学「什么叫相似」。比如：题目向量和知识点向量不在同一语义空间时，余弦会失真，Bilinear 能自适应校正。	训练 W（约 147K 参数） 用 Recall@10 做监督 替换 brier_eval.py 中的 cosine_similarity
L1 距离	两个向量各有 384 个数字，逐位相减取绝对值后求和 = 总差距 d； sim = 1/(1+d) (d=0时sim=1，越大越小)	余弦忽略向量长度，但 384 维向量里某些维度可能本身很大（噪声维度）。L1 逐维求差，对这类高维噪声更鲁棒。	3 行代码替换 cosine_similarity 无需任何训练
知识图谱 辅助距离	sim = a*cos(u,v) + (1-a)*w_KG a 为混合权重 w_KG 为图边权	纯向量相似度只看统计共现，看不到化学概念之间的结构关系（如「酸碱反应」→「pH」是一条已知的强关联）。引入知识图谱边权，把已知化学关系直接编入相似度计算中。	需先构建化学知识图谱 (ChemOnt / PubChem) 映射题目→图节点 工作量较大，作为长期方向

③ 扩充数据集
从 ChemBench / SciQ 获取 >1 万道化学题，重测 CALM Adapter，验证数据量是否确实是可训练压缩的瓶颈。

④ 多指标联合评估
计算 VecBrierLM 与 Recall@10、Separation 的 Pearson 相关系数，判断各指标是否可互相替代，进一步精简评估流程。

— 报告完 —